



Herman Hollerith Zentrum



Hochschule Reutlingen
Reutlingen University

Artificial Intelligence Fallstudie

AUSWERTUNG DES ADIDAS AG US SALES DATASETS



Maurice Neidhart

M. SC. DIGITAL BUSINESS ENGINEERING STUDENT | HHZ BÖBLINGEN DER HS REUTLINGEN

Inhaltsverzeichnis

| | |
|--|-----------|
| 1. Unternehmensbeschreibung | 2 |
| 2. Problem- und Fragestellungen | 3 |
| 3. Einordnung in den Bereich Machine Learning | 5 |
| 4. Datenbeschreibung und Datenerfassung..... | 8 |
| 5. Modellbildung, Datenanalyse und Algorithmen..... | 10 |
| 6. Datenbasierte Services | 12 |
| 7. Relevante Effekte für das Unternehmen Adidas | 13 |
| 8. Quellen..... | 15 |

1. Unternehmensbeschreibung

Adidas AG ist mit über 22 Millionen Euro Nettoumsatz weltweit im Jahr 2022, ein global führendes Unternehmen in der Sportartikelindustrie [1]. Das Unternehmen wurde 1949 von Adolf Dassler in Herzogenaurach, Deutschland, gegründet. Mit seinem ikonischen Drei-Streifen-Logo und seinem Slogan „Impossible is Nothing“ ist Adidas bekannt für seine hochwertigen Sportschuhe, Bekleidung und Zubehör. Der Konzern hat sich über die Jahrzehnte hinweg zu einem Symbol für Leistung und Stil im Sport und in der Freizeitmode entwickelt.



Abbildung 1: Adidas Werbung mit dem Slogan „impossible is nothing“

Der US-Markt ist für Adidas von strategischer Bedeutung, da der amerikanische Sportbekleidungsmarkt mit über 18 Milliarden US-Dollar einer der größten und wettbewerbsintensivsten Märkte für Sportbekleidung und -ausrüstung weltweit ist [2]. Adidas hat in den USA durch Partnerschaften mit berühmten Athleten und Prominenten sowie durch Innovationen im Produktbereich Erfolge erzielt. Die Einführung von Technologien wie Boost und Primeknit hat Adidas geholfen, in den USA an Popularität zu gewinnen, insbesondere unter jüngeren Konsumenten.

Im Bereich Retail und Verkauf in den USA steht Adidas jedoch vor einigen Herausforderungen. Der zunehmende Wettbewerb durch lokale und internationale Marken wie Nike und Under Armour stellt Adidas vor die Aufgabe, sich kontinuierlich zu differenzieren und innovativer zu werden. Zudem hat der Wandel im Konsumverhalten mit einem Anstieg des Online-Handels Adidas dazu veranlasst, seine digitalen Verkaufskanäle zu stärken und ein nahtloses Einkaufserlebnis sowohl online als auch in physischen Stores zu bieten.

Darüber hinaus hat Adidas in den USA mit Herausforderungen in Bezug auf Nachhaltigkeit und soziale Verantwortung zu kämpfen. Das Unternehmen hat auf diese Herausforderungen reagiert, indem es nachhaltigere und sozialere Produktionsmethoden eingeführt hat. Diese Bemühungen haben dazu beigetragen, das Markenimage von Adidas zu stärken und seine Kundenbasis zu erweitern.

Zusammenfassend ist Adidas in den USA sowohl mit Erfolgen als auch Herausforderungen konfrontiert. Während die Marke in Bezug auf Innovation und Popularität gewachsen ist, muss sie sich weiterhin an die sich ändernden Marktbedingungen und Verbraucherbedürfnisse anpassen, um ihre führende Position zu behaupten. Die Auswertung des Adidas US Sales Datensatzes können dem Unternehmen hierbei helfen.

2. Problem- und Fragestellungen

Die Auswertung von des Verkaufsdatensatzes mit Python und Machine Learning bietet der Adidas AG zahlreiche Möglichkeiten, um wertvolle Einblicke in den Verkauf auf dem wichtigen amerikanischen Markt zu gewinnen und strategische Entscheidungen zu treffen.

Für die Auswertung der Daten, wird das CRISP-DM (Cross-Industry Standard Process for Data Mining) Modell, zur Vorgehensweise gewählt. Das CRISP-DM Modell hilft dabei, Datenanalyseprojekte systematisch anzugehen, indem es klare Schritte von der Problemdefinition bis zur Datenbewertung vorgibt. Es lehrt, die Relevanz und Qualität von Daten zu beurteilen und sie effektiv für Analysen vorzubereiten. Durch Anwendung verschiedener Modellierungstechniken ermöglicht es, tiefe Einblicke aus Daten zu gewinnen und die Ergebnisse kritisch zu evaluieren.



Abbildung 2: CRISP-DM Modell

Eine Schlüsselkomponente in diesem Prozess ist die **Nachfragevorhersage**, die es ermöglicht, zukünftige Verkaufstrends basierend auf historischen Daten vorherzusagen. Dies ist besonders wertvoll für die Optimierung der Bestandsverwaltung und die Vermeidung von Überbeständen, was wiederum Kosten senkt, und die Effizienz steigert.

Ein weiteres wichtiges Anwendungsfeld ist die **Preisoptimierung**. Durch die Analyse verschiedener Faktoren wie Nachfrage, Preis und den Verkaufstag kann Machine Learning dazu beitragen, den idealen Verkaufspreis für Produkte zu bestimmen. Dies führt nicht nur zu einer Verbesserung der Gewinnmargen, sondern auch zu einer erhöhten Kundenzufriedenheit, da die Preise marktgerecht gestaltet werden.

Die **Kundenanalyse und Segmentierung** sind ebenfalls von großer Bedeutung. Durch das Verständnis von Kundenverhalten und regionalen Daten können unterschiedliche Kundensegmente identifiziert und gezielte Marketingstrategien entwickelt werden. Dies erhöht die Effektivität von Werbe- und Verkaufsförderungsmaßnahmen, da Angebote und Kommunikation auf die spezifischen Bedürfnisse der Kunden zugeschnitten werden können.

Eine tiefergehende Untersuchung des **Zusammenhangs zwischen dem Gesamtumsatz und dem Betriebsergebnis** zeigt auf, wie effizient die Adidas AG ihre Ressourcen einsetzt, um Umsätze zu generieren. Hierbei kann Machine Learning eingesetzt werden, um Muster und Korrelationen zwischen diesen beiden

Kennzahlen zu identifizieren, was Adidas dabei helfen würde, Bereiche zu identifizieren, in denen die Effizienz gesteigert werden kann.

Eine detaillierte **Untersuchung der Verkaufskanäle** würde aufzeigen, welche Kanäle (z.B. Online-Verkauf, Einzelhandelsgeschäfte) am effektivsten sind und wie verschiedene Verkaufsmethoden den Umsatz beeinflussen. Dies könnte dazu beitragen, Ressourcen auf die profitabelsten Kanäle zu konzentrieren und die Verkaufsstrategien entsprechend anzupassen.

Durch die **Analyse der Preisverteilung und der Verkaufsmengen** verschiedener Produkte kann Adidas besser verstehen, welche Preisstrategien für verschiedene Produkte oder Produktkategorien am besten funktionieren. Dies ist besonders wichtig für die Preisoptimierung und die Bestimmung von Preiselastizitäten.

Durch die **Identifizierung der Bestseller** kann Adidas wertvolle Einblicke gewinnen, welche Produkte am beliebtesten sind und warum. Dies kann helfen, zukünftige Produktentwicklungen und Marketingstrategien auf die erfolgreichsten Produkte auszurichten.

Schließlich ermöglicht die **Trendanalyse und Marktbeobachtung** die Identifizierung aufkommender Modetrends und Marktveränderungen, um schnell auf Kundenbedürfnisse reagieren zu können. Dies ist besonders wichtig in der schnelllebigen Modeindustrie, wo Trends sich rasch ändern.

Fazit:

Eine Datenanalyse mit Python und Machine Learning bietet der Adidas AG vielfältige Möglichkeiten, um operative Effizienz zu steigern, Kundenbindung zu verbessern und innovativ auf Markttrends zu reagieren.

3. Einordnung in den Bereich Machine Learning

Die Daten des Datensatzes Adidas US Sales Daten können auf verschiedene Weisen im Bereich des maschinellen Lernens verwendet werden. Einige mögliche Anwendungen und die Einordnung dieser Analyse in den Bereich des maschinellen Lernens sind:

1. Vorhersagemodelle:

- Umsatzprognosen: Einsatz von Regressionsmodellen, um zukünftige Verkaufszahlen basierend auf historischen Daten zu prognostizieren. Dies kann für Bestandsmanagement, Marketingstrategien und Ressourcenplanung von Bedeutung sein.
- Nachfragevorhersage: Einsatz von Zeitreihenanalyse- und Prognosemodellen, um die Nachfrage nach verschiedenen Produkten in verschiedenen Regionen vorherzusagen.

2. Klassifikationsmodelle:

- Kundenklassifizierung: Nutzen von Klassifikationsalgorithmen, um Kunden in verschiedene Segmente zu unterteilen, basierend auf Kaufverhalten, Vorlieben und demografischen Merkmalen.
- Produktempfehlungen: Einsatz von Empfehlungssystemen, um personalisierte Produktempfehlungen für Kunden zu generieren.

3. Clustering und Marktsegmentierung:

- Regionale Marktanalyse: Anwendung von Clustering-Verfahren, um Regionen oder Städte zu identifizieren, die ähnliche Verkaufsmuster aufweisen, was bei der Entscheidungsfindung für Marketing und Expansion helfen kann.

4. Zeitreihenanalyse:

- Trendanalyse: Analyse von Verkaufstrends über die Zeit, um saisonale Muster und Trends in der Popularität verschiedener Produkte zu identifizieren.

Anwendung von Machine Learning Modellen

```
# Predicting Total Sales based on Units Sold
X = data_sales_adidas[['Units Sold']]
y = data_sales_adidas['Total Sales']

# Splitting the dataset into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=0)

# Create and train the model
model = LinearRegression()
model.fit(X_train, y_train)

# Make predictions and evaluate the model
predictions = model.predict(X_test)
print("Mean Squared Error:", mean_squared_error(y_test, predictions))
```

Mean Squared Error: 2920347423.5949826

Abbildung 3: Machine Learning Modell

Der Code der Abbildung 3 zeigt die Erstellung eines linearen Regressionsmodells zur Vorhersage der Gesamtverkäufe basierend auf den verkauften Einheiten (Units Sold) für Adidas-Produktdaten darstellt. Nach dem Training des Modells wird eine Vorhersage durchgeführt und der Mean Squared Error (MSE) der Vorhersage berechnet. Der MSE ist ein Maß für die Qualität einer Schätzung und gibt an, wie nahe die Vorhersagen der tatsächlichen Werte liegen, wobei niedrigere Werte eine bessere Anpassung bedeuten.

Der MSE ist mit ca. 2920347423 sehr hoch, was auf eine schlechte Modellanpassung hinweisen könnte. Ein hoher MSE bedeutet, dass die vorhergesagten Werte erheblich von den tatsächlichen Werten abweichen.

```
# Convert 'Invoice Date' to datetime and extract year
data_sales_adidas['Invoice Date'] = pd.to_datetime(data_sales_adidas['Invoice Date'])
data_sales_adidas['Year'] = data_sales_adidas['Invoice Date'].dt.year

# Summarize the data by year and region
annual_sales_by_region = data_sales_adidas.groupby(['Year', 'Region']).agg({'Total Sales': 'sum'}).reset_index()

# Extracting regions from the dataset
regions = data_sales_adidas['Region'].unique()

# Simple Linear Regression for each region
linear_forecasts = {}

for region in regions:
    # Prepare data for regression
    region_data = annual_sales_by_region[annual_sales_by_region['Region'] == region]
    X = region_data['Year'].values.reshape(-1, 1) # Independent variable (Year)
    y = region_data['Total Sales'].values # Dependent variable (Total Sales)

    # Fit linear regression model
    model = LinearRegression().fit(X, y)

    # Predicting for 2024
    forecast_year = np.array([2024]).reshape(-1, 1)
    forecast = model.predict(forecast_year)
    linear_forecasts[region] = forecast[0]

# Display the forecasts
linear_forecasts
```

```
{'Northeast': 460048305.0,
 'South': 400454550.0,
 'West': 541506657.0,
 'Midwest': 491555360.0,
 'Southeast': 431478903.0}
```

Abbildung 4: Machine Learning Forecast

Der Code der Abbildung 4 konvertiert zunächst die 'Invoice Date'-Spalte in ein Datumsformat und extrahiert das Jahr. Anschließend fasst er die Daten jährlich und nach Regionen zusammen, indem er die Gesamtumsätze ('Total Sales') aggregiert und den Index des resultierenden DataFrames zurücksetzt.

Für jede Region wird eine einfache lineare Regression durchgeführt, wobei die Jahre als unabhängige Variable (Prädiktor) und die jährlichen Gesamtumsätze als abhängige Variable (Antwort) verwendet werden.

Es wird zudem, das 'LinearRegression'-Modell aus der 'sklearn.linear_model'-Bibliothek verwendet, einer weit verbreiteten Bibliothek für maschinelles Lernen in Python. Die Lineare Regression eine grundlegende Methode des überwachten Lernens im maschinellen Lernen, die verwendet wird, um eine lineare Beziehung zwischen einer abhängigen Variable und einer (oder mehreren) unabhängigen Variablen zu modellieren.

Mögliche Datenbasierte Services könnten sein:

- Umsatzprognosen: Auf der Grundlage der jährlichen Gesamtumsätze könnte dieses Modell zur Vorhersage zukünftiger Umsätze für jede Region verwendet werden, was für Budgetierung und strategische Planung nützlich sein kann.
- Trendanalyse: Durch die Analyse der Steigung der Regressionslinie könnten Unternehmen Trends in den Verkaufszahlen identifizieren und darauf basierend Marketingstrategien anpassen.
- Ressourcenallokation: Unternehmen könnten den Code nutzen, um zu entscheiden, wie Ressourcen basierend auf erwarteten Umsatzänderungen verteilt werden sollten.

Der Code ist ein Beispiel für den praktischen Einsatz von Python und maschinellem Lernen für die Datenanalyse und Prognose in der Geschäftswelt. Er zeigt, wie man mit Hilfe einfacher Modelle aus historischen Daten Einblicke gewinnen und

vorhersagende Analysen durchführen kann. Solche Modelle sind wertvolle Werkzeuge für datengesteuerte Entscheidungsfindung in Organisationen.

```
# Data Cleaning and Preparation
data_sales_adidas['RollingAvg_UnitsSold_30d'] = data_sales_adidas.groupby(['Product', 'City'])['Units Sold'].transform(lambda x: x.rolling(30).mean().fillna(0, inplace=True))

# Extracting time-related features
data_sales_adidas['Year'] = data_sales_adidas['Invoice Date'].dt.year
data_sales_adidas['Month'] = data_sales_adidas['Invoice Date'].dt.month
data_sales_adidas['Week'] = data_sales_adidas['Invoice Date'].dt.isocalendar().week
data_sales_adidas['DayOfWeek'] = data_sales_adidas['Invoice Date'].dt.dayofweek

# Selecting relevant features for the model
features = ['Year', 'Month', 'Week', 'DayOfWeek', 'RollingAvg_UnitsSold_30d']
target = 'Units Sold'

# Preparing the features and target variable
X = data_sales_adidas[features]
y = data_sales_adidas[target]

# Normalizing the features
scaler = MinMaxScaler()
X_scaled = scaler.fit_transform(X)

# Splitting the data into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(X_scaled, y, test_size=0.2, random_state=42)

# Building the Linear Regression model
model = LinearRegression()

# Training the model
model.fit(X_train, y_train)

# Make predictions using the testing set
y_pred = model.predict(X_test)

# The coefficients
print('Coefficients: \n', model.coef_)

# The mean squared error
print('Mean squared error: %.2f' % mean_squared_error(y_test, y_pred))

# The coefficient of determination: 1 is perfect prediction
print('Coefficient of determination: %.2f' % model.score(X_test, y_test))

Coefficients:
[-108.5903895   52.71635129  -57.32922667  -11.92050849  -201.35017609]
Mean squared error: 44313.26
Coefficient of determination: 0.06
```

Abbildung 5: Machine Learning for MSE and Coefficient

In der Abbildung 5 wird eine Auswahl von Features für das Modell getroffen, einschließlich 'Week', 'DayOfWeek' und den rollenden Durchschnitt der verkauften Einheiten. Als Zielvariable ('target') wird 'Units Sold' verwendet, da das Ziel des Modells darin besteht, Verkaufszahlen vorherzusagen.

Mögliche datenbasierte Services könnten sein:

- Absatzprognose: Die Verwendung von zeitlichen Features und rollenden Durchschnitt kann dazu dienen, Verkaufsprognosen für Produkte oder Dienstleistungen zu erstellen.
- Lagerbestandsmanagement: Unternehmen könnten dieses Modell nutzen, um zukünftigen Lagerbedarf vorherzusagen und die Lagerbestände zu optimieren.
- Preisstrategieoptimierung: Mit genauen Verkaufsprognosen könnten Preisstrategien angepasst werden, um die Umsätze zu maximieren.

Der Code ist ein Beispiel für die Anwendung von Zeitreihenanalyse und Vorhersagemodellen im Bereich des maschinellen Lernens. Die Bewertungsmetriken zeigen, dass das Modell eine gewisse Vorhersagekraft hat, die für geschäftsbezogene Entscheidungsfindungen genutzt werden kann.

Fazit:

Zusammenfassend bietet dieser Datensatz zahlreiche Möglichkeiten für den Einsatz von maschinellem Lernen, um wertvolle Erkenntnisse für Geschäftsentscheidungen zu gewinnen und die Effizienz von Verkaufs- und Marketingstrategien zu verbessern.

4. Datenbeschreibung und Datenerfassung

Der Datensatz „Data Sales Adidas“ von Kaggle [3] enthält detaillierte Informationen über den Verkauf von Adidas-Produkten in den USA. Im Folgenden wird eine Beschreibung der Daten und deren Erfassung vorgenommen.

Datenbeschreibung

Der Datensatz "Data Sales Adidas" umfasst 13 Spalten und 9647 Einträge, die verschiedene Aspekte des Verkaufsprozesses abbilden. Diese sind:

1. Retailer: Name des Einzelhändlers, der die Adidas-Produkte verkauft.
2. Retailer ID: Eine eindeutige Identifikationsnummer für den Einzelhändler.
3. Invoice Date: Das Datum der Rechnung, welches den Verkaufstag repräsentiert.
4. Region: Die geografische Region in den USA, in der der Verkauf stattfand.
5. State: Der Bundesstaat innerhalb der Region.
6. City: Die Stadt, in der der Einzelhändler sich befindet.
7. Product: Die genaue Bezeichnung des verkauften Adidas-Produkts.
8. Price per Unit: Der Preis pro Einheit des Produkts.
9. Units Sold: Die Anzahl der verkauften Einheiten.
10. Total Sales: Der Gesamtumsatz, der sich aus dem Produkt von "Price per Unit" und "Units Sold" ergibt.
11. Operating Profit: Der Betriebsgewinn aus dem Verkauf.
12. Operating Margin: Die Betriebsmarge, ein Maß für die Rentabilität.
13. Sales Method: Die Verkaufsmethode (z.B. In-store).

Datenerfassung

Die Datenerfassung für diesen Datensatz erfolgt vermutlich durch die systematische Aufzeichnung von Verkaufstransaktionen bei verschiedenen Einzelhändlern. Jede Transaktion wird mit Datum, Produktinformationen, Verkaufszahlen und finanziellen Kennzahlen erfasst. Die Daten könnten aus den Verkaufssystemen der Einzelhändler oder direkt aus dem Vertriebssystem von Adidas stammen. Die systematische Erfassung ermöglicht eine detaillierte Analyse von Verkaufstrends, regionalen Unterschieden, Produktleistung und finanzieller Performance.

Analysemöglichkeiten

Mit diesem Datensatz können verschiedene Analysen durchgeführt werden, wie zum Beispiel:

- Umsatzanalyse nach Region, Bundesstaat oder Stadt.
- Produktleistungsanalyse, um festzustellen, welche Produkte am besten abschneiden.
- Trendanalyse über Zeit, um saisonale Muster oder Veränderungen im Kaufverhalten zu identifizieren.
- Rentabilitätsanalyse, um die Profitabilität verschiedener Produkte oder Verkaufsstrategien zu bewerten.

Diese Daten bieten somit wertvolle Einblicke für strategische Entscheidungen im Vertrieb und Marketing bei Adidas. Die Excel-Datei "Adidas US Sales Datasets" bietet eine umfassende Datensammlung, die für Adidas und seine Vertriebspartner von großem Wert ist. Die Daten ermöglichen eine tiefgehende Analyse verschiedener Aspekte des Verkaufsprozesses und bieten Einblicke in Markttrends, Kundenpräferenzen und betriebliche Effizienz. Im Folgenden wird die Datenbeschreibung und Datenerfassung weiter vertieft.

Erweiterte Datenbeschreibung

Jede Spalte in der Datenbank trägt zur Gesamtübersicht des Verkaufsprozesses bei:

1. Retailer und Retailer ID: Diese Spalten bieten Einblicke in das Vertriebsnetz von Adidas. Sie ermöglichen die Identifikation von Schlüsseleinzelhändlern und die Bewertung ihrer Leistung.
2. Invoice Date: Die Datumsangaben sind essenziell für die zeitliche Analyse des Verkaufs. Sie ermöglichen es, saisonale Trends und Veränderungen im Zeitverlauf zu identifizieren. Die Daten reichen vom 01.01.2020 bis zum 31.12.2021.
3. Region, State, City: Diese geografischen Daten sind wichtig, um regionale Verkaufstrends zu analysieren. Sie können aufzeigen, in welchen Gebieten Adidas-Produkte besonders beliebt sind oder wo Verkaufsanstrengungen intensiviert werden könnten.
4. Product: Die genaue Kenntnis darüber, welche Produkte verkauft werden, ist entscheidend, um das Produktportfolio von Adidas zu optimieren.
5. Price per Unit, Units Sold, Total Sales: Diese finanziellen Daten geben Aufschluss über Umsatztrends, Preisstrategien und Kundennachfrage.
6. Operating Profit, Operating Margin: Diese Kennzahlen sind wichtig, um die Rentabilität des Vertriebs zu bewerten. Sie zeigen, wie effektiv Adidas und seine Einzelhändler die Kosten kontrollieren und Gewinn erzielen.
7. Sales Method: Die Unterscheidung nach Verkaufsmethoden (z.B. In-Store, Online) ist besonders in der heutigen, digital dominierten Handelslandschaft wichtig.

Potenzielle Anwendungen der Daten

- Zielgruppenanalyse: Durch die Analyse der Daten können spezifische Kundensegmente identifiziert werden, die besonders auf bestimmte Produkte ansprechen.
- Preisoptimierung: Die Daten können verwendet werden, um Preispunkte zu finden, die das Gleichgewicht zwischen Umsatz und Profit maximieren.
- Lagerbestandsmanagement: Die Analyse von Verkaufstrends hilft bei der Optimierung der Lagerbestände, um Überbestände zu vermeiden und gleichzeitig die Nachfrage zu decken.
- Marketingstrategien: Die Daten bieten wertvolle Einblicke für gezielte Marketingkampagnen und Werbeaktionen.

Fazit:

Zusammenfassend stellen die "Adidas US Sales Datasets" einen wertvollen Datenschatz dar, der Adidas und seinen Partnern hilft, Verkaufsstrategien zu verfeinern, Kunden besser zu verstehen und letztendlich ihre Marktposition zu stärken.

5. Modellbildung, Datenanalyse und Algorithmen

Der "Adidas US Sales Datasets" Datensatz bietet eine ausgezeichnete Grundlage für fortgeschrittene Modellbildung, Datenanalyse und die Anwendung von Algorithmen. Die Nutzung dieser Techniken kann Adidas dabei helfen, wertvolle Einblicke aus den Daten zu gewinnen, um Geschäftsentscheidungen zu optimieren und neue Strategien zu entwickeln. Im Folgenden werden die Möglichkeiten der Modellbildung, Datenanalyse und Algorithmen im Kontext dieses Datensatzes erläutert.

Modellbildung

Die Analyse und Visualisierung von Daten ist ein wesentlicher Schritt, um komplexe Muster und Zusammenhänge im Adidas-Datensatz zu erkennen. Folgende Methoden könnten in diesem Kontext besonders relevant sein:




Abbildung 6: Heatmap zur Visualisierung der Daten

1. Heatmaps: Diese visuellen Werkzeuge der Korrelationsmatrix der Verkaufsdaten könnten (siehe Abbildung 6) genutzt werden, um Verkaufstrends und Kundenverhalten über die Zeit zu illustrieren. Sie sind besonders hilfreich, um Muster im Verkauf auf einen Blick zu erfassen. Die Korrelation misst den Grad der Beziehung zwischen zwei Variablen und liegt im Bereich von -1 bis +1. Ein Wert von +1 bedeutet eine perfekte positive Korrelation, 0 keine Korrelation und -1 eine perfekte negative Korrelation.

2. Lineare Regression: Diese Methode könnte angewendet werden, um die Beziehung zwischen verschiedenen Faktoren, wie dem Preis eines Produkts und dessen Verkaufszahlen, zu analysieren. Dies hilft dabei, Vorhersagen über zukünftige Verkäufe basierend auf Preisänderungen zu treffen.

3. Verteilungsanalyse: Durch die Analyse der Verteilung von Verkaufszahlen oder Kundenmerkmalen können Einsichten über verschiedene Segmente oder Produktkategorien gewonnen werden. Dies ist nützlich, um Zielgruppen besser zu verstehen und Angebote gezielt anzupassen.

4. Balken- und Kuchendiagramme: Diese klassischen Diagrammtypen eignen sich hervorragend, um Verkaufszahlen, Kundenprofile oder Produktbeliebtheit in verschiedenen Regionen oder Zeiträumen übersichtlich darzustellen. Sie erleichtern den Vergleich verschiedener Kategorien und unterstützen effektive Entscheidungsfindungen.

Datenanalyse

Die Datenanalyse ist der Prozess der Untersuchung, Reinigung, Transformation und Modellierung von Daten mit dem Ziel, nützliche Informationen, Schlussfolgerungen und Unterstützung von Entscheidungsfindung zu gewinnen. Im Kontext des Adidas Datensatzes könnten folgende Analysen durchgeführt werden:

1. Deskriptive Analyse: Diese Analyse befasst sich mit der Beschreibung der aktuellen Verkaufsdaten, um ein grundlegendes Verständnis der Performance verschiedener Produkte oder Regionen zu erhalten.
2. Explorative Datenanalyse (EDA): EDA hilft, verborgene Muster, Anomalien oder Beziehungen in den Daten zu entdecken. Dies ist ein kritischer Schritt vor der Anwendung komplexerer Modelle.
3. Prädiktive Analyse: Hierbei werden Modelle eingesetzt, um zukünftige Ereignisse auf Basis historischer Daten vorherzusagen, wie z.B. zukünftige Verkaufszahlen oder Markttrends.

Algorithmen

Verschiedene Algorithmen können auf den Adidas Datensatz angewendet werden, um spezifische Probleme zu lösen oder Einblicke zu gewinnen:

1. Maschinelles Lernen Algorithmen: Algorithmen wie Entscheidungsbäume, Random Forest, Gradient Boosting oder neuronale Netze können für prädiktive Modellierung oder Kundenklassifizierung verwendet werden.
2. Optimierungsalgorithmen: Diese können eingesetzt werden, um die Lagerbestände zu optimieren oder die dynamische Preisgestaltung zu verbessern.
3. Zeitreihenanalysen: Algorithmen wie LSTM (Long Short-Term Memory) könnten verwendet werden, um Verkaufstrends über die Zeit zu analysieren und Vorhersagen zu treffen.

Fazit:

Zusammenfassend lässt sich sagen, dass die Kombination aus Modellbildung, Datenanalyse und Algorithmen bietet Adidas eine mächtige Werkzeugpalette, um aus dem "Adidas US Sales" Datensatz maximalen Nutzen zu ziehen. Diese Techniken ermöglichen es Adidas, tiefergehende Einblicke in das Kundenverhalten zu gewinnen, die Marktdynamik besser zu verstehen und letztlich fundiertere, datengestützte Entscheidungen zu treffen. Der Einsatz dieser fortgeschrittenen Methoden kann Adidas dabei unterstützen, seine Wettbewerbsfähigkeit zu stärken und in einem sich schnell verändernden Marktumfeld erfolgreich zu sein.

6. Datenbasierte Services

Der Datensatz "Adidas US Sales Datasets" bietet eine Fülle von Informationen, die für datenbasierte Services genutzt werden können. Solche Services sind in der heutigen, datengesteuerten Geschäftswelt von entscheidender Bedeutung, da sie Unternehmen dabei helfen, effizientere, kundenzentriertere und innovativere Strategien zu entwickeln. Im Folgenden werden einige potenzielle datenbasierte Services beschrieben, die aus diesem Datensatz entwickelt werden könnten.

1. Personalisierte Marketingempfehlungen

Durch die Analyse der Verkaufsdaten, insbesondere der Produktpräferenzen in den Regionen und Städten sowie Kaufmuster verschiedener Kunden, könnten personalisierte Marketingstrategien entwickelt werden. Diese würden es Adidas ermöglichen, zielgerichtete Werbung und Promotionen zu erstellen, die auf die spezifischen Interessen und Bedürfnisse der Kunden zugeschnitten sind.

2. Optimierung der Lagerhaltung und Lieferkette

Die Daten bieten wertvolle Einblicke in Verkaufstrends und Produktbeliebtheit. Mithilfe von Vorhersagemodellen könnten datenbasierte Services entwickelt werden, die dabei helfen, die Lagerbestände zu optimieren und die Lieferkette effizienter zu gestalten. Dies würde nicht nur Kosten sparen, sondern auch sicherstellen, dass Produkte rechtzeitig verfügbar sind, um die Nachfrage zu decken.

3. Dynamische Preisgestaltung

Der Datensatz enthält detaillierte Informationen über Verkaufspreise und Absatzmengen. Durch die Analyse dieser Daten könnten Algorithmen für eine dynamische Preisgestaltung entwickelt werden, die Preise in Echtzeit anhand von Nachfrage, Lagerbeständen und Marktbedingungen anpassen.

4. Regionale Markteinblicke und Expansionsstrategien

Durch die Analyse regionaler Verkaufsdaten könnten Services entwickelt werden, die Einblicke in die Marktdynamik und Kundenpräferenzen in verschiedenen geografischen Gebieten bieten. Dies könnte Adidas dabei unterstützen, gezielte Expansionsstrategien zu entwickeln und Marketingbemühungen in vielversprechenden Regionen zu intensivieren.

5. Vorhersageanalysen für neue Produktlinien

Der Datensatz könnte genutzt werden, um Trends und Muster in der Produktbeliebtheit zu identifizieren. Diese Erkenntnisse könnten dann für Vorhersageanalysen verwendet werden, um das Potenzial neuer Produktlinien oder Designs zu bewerten.

Fazit

Der "Adidas US Sales Datasets"-Datensatz bietet zahlreiche Möglichkeiten für die Entwicklung datenbasierter Services. Diese Services können Adidas helfen, seinen Betrieb zu optimieren, besser auf Kundenbedürfnisse einzugehen und letztendlich seine Marktposition zu stärken. Die Nutzung dieser Daten für intelligente, datengesteuerte Entscheidungen ist ein wesentlicher Schritt hin zu einem agileren und kundenorientierteren Geschäftsmodell.

7. Relevante Effekte für das Unternehmen Adidas

Der Datensatz "Adidas US Sales Datasets" bietet Adidas eine Fülle an Informationen, die für das Unternehmen in vielerlei Hinsicht relevant sind. Diese Daten können genutzt werden, um wichtige Einblicke in verschiedene Aspekte des Geschäfts zu gewinnen und effektive Strategien zu entwickeln. Im Folgenden werden einige der relevanten Effekte, die sich aus der Analyse und Nutzung dieses Datensatzes für Adidas ergeben können, detailliert beschrieben.

1. Verbesserte Kundenkenntnisse

Die Daten ermöglichen es Adidas, ein tiefes Verständnis seiner Kunden zu entwickeln. Durch die Analyse von Produktpräferenzen und regionalen Trends kann Adidas besser verstehen, was seine Kunden wünschen und benötigen. Diese Kenntnisse sind entscheidend für die Entwicklung von Produkten, die genau auf die Bedürfnisse und Wünsche der Zielgruppe zugeschnitten sind.

2. Effizienzsteigerung in der Lieferkette

Die Informationen über Verkaufszahlen, Lagerbestände und regionale Nachfragen erlauben es Adidas, seine Lieferkette zu optimieren. Dies umfasst eine effizientere Lagerhaltung, eine bessere Prognose der Nachfrage und eine schnellere Reaktion auf Marktveränderungen. Dadurch kann Adidas Kosten reduzieren und gleichzeitig die Verfügbarkeit seiner Produkte verbessern. Gleichzeitig erlaubt die Analyse des Datensatzes auch einen Einblick in die Performance der Händler und welche Verkaufskanäle Kunden bei der Bestellung bevorzugen. Adidas sollte sich insbesondere auf den Onlinehandel stärker Fokussieren, da hier die Kunden am häufigsten bestellt hatten. Auch ein Fokus auf die Großstädte wie New York oder San Francisco wäre zu empfehlen, da in diesen Städten viele Produkte verkauft werden und die Anzahl der Verkäufe auch direkt mit dem Operating Profit zusammenhängt.

3. Strategische Markteinblicke

Die Daten geben Aufschluss über die Leistung verschiedener Produkte in verschiedenen Regionen. Adidas kann diese Informationen nutzen, um strategische Entscheidungen über Produktentwicklungen und Marketingstrategien zu treffen. Insbesondere die Identifikation von starken und schwachen Regionen ist hierbei von großer Bedeutung.

4. Personalisierung des Marketings

Durch die Nutzung der Verkaufsdaten kann Adidas personalisierte Marketingkampagnen entwickeln, die auf spezifische Kundensegmente ausgerichtet sind. Dies verbessert nicht nur die Effektivität der Marketingbemühungen, sondern erhöht auch die Kundenzufriedenheit und -bindung.

5. Wettbewerbsvorteile

Die Analyse der Verkaufsdaten bietet Adidas wertvolle Einblicke in die Marktdynamik und hilft, Wettbewerbsvorteile zu identifizieren und zu nutzen. Durch das Verständnis der eigenen Verkäufe in den USA, kann Adidas gezielte Strategien entwickeln, um sich einen Vorteil zu verschaffen.

6. Produktentwicklung und Innovation

Die Daten können Aufschluss über Trends und Kundenpräferenzen geben, was für die Entwicklung neuer Produkte entscheidend ist. Adidas kann so gezielt in Produkte

investieren, die wahrscheinlich erfolgreich sein werden, und gleichzeitig das Risiko von Fehlinvestitionen minimieren.

7. Dynamische Preisgestaltung

Der Datensatz ermöglicht eine dynamische Preisgestaltung, basierend auf Echtzeit-Daten über Nachfrage, Wettbewerb und Markttrends. Dies kann dazu beitragen, den Umsatz zu maximieren und gleichzeitig auf Marktveränderungen flexibel zu reagieren.

Fazit

Die Analyse und Nutzung des "Adidas US Sales Datasets" bietet Adidas vielfältige Möglichkeiten, seine Geschäftsstrategien zu verbessern, effizienter zu werden und auf einem hart umkämpften Markt erfolgreich zu sein. Die daraus resultierenden Erkenntnisse ermöglichen es Adidas, schneller auf Markttrends zu reagieren, kundenorientierter zu agieren und letztendlich seine Marktposition zu stärken. In einer Zeit, in der datengesteuerte Entscheidungen zunehmend wichtig werden, stellt dieser Datensatz ein wertvolles Werkzeug für Adidas dar, um nachhaltigen Erfolg zu erzielen.

8. Quellen

[1] Statista (2022): The adidas Group's net sales worldwide from 2000 to 2022, statista, [online], <https://www.statista.com/statistics/268416/net-sales-of-the-adidas-group-worldwide-since-2000/> [abgerufen am 21.12.2023]

[2] MaximizeMarketResearch (2023): Sports Apparel Market – Global Industry Analysis and Forecast, Maximize Market Research, [online], <https://www.maximizemarketresearch.com/market-report/sports-apparel-market/83971/#:~:text=Sports%20Apparel%20Market%20was%20valued,for%20physical%20activity%20or%20sport> [abgerufen am 21.12.2023]

[3] Kaggle (2022): Adidas Sales Dataset, Kaggle, [online], <https://www.kaggle.com/datasets/heemalichaudhari/adidas-sales-dataset/data> [abgerufen am 21.12.2023]

Das Repository zu dem Code und dem Datensatz kann unter folgendem Link gefunden werden:

<https://github.com/Maurice73-Tech/Adidas-Data-Analysis>